Hito 2: Ingeniería de Datos, EDA y Línea Base Verificada bajo CRISP-ML(Q)

Repositorio: fraud-detection-crisp-ml | Ruta C (Russell & Norvig caps. 19-21) | Semilla: seed=42 | SHA-256 Base.csv: 7bf10a37...dcf9b809

1. Preparación de Datos Verificada y Hallazgos del EDA (notebooks/01_eda_baf.ipynb)

- Integridad y Eficiencia en RAM: Se descargó y verificó data/raw/Base.csv (BAF NeurIPS 2022, 1,000,000 filas x 32 cols, 213.43 MB, licencia CC BY-NC-SA 4.0, cero PII, 0 NaN literales y 0 duplicados). El tipado compacto (float32/int32/int8/category) redujo la RAM de 458.45 MB a 84.88 MB (-81.49%) en 1M de filas y a 8.49 MB en la muestra estratificada oficial (n=100,000, seed=42).
- Estratificación y Deriva Temporal: La prevalencia real de fraude (1.1029%, razón ~1:89.7) se preservó en la muestra (1.1030%) y en los splits Train (70,000; 1.1029%), Val (15,000; 1.1067%) y Test (15,000; 1.1000%). El EDA por month (0-7) evidenció no estacionariedad: el fraude desciende de 1.13% (mes 0) a 0.87% (mes 2) y sube a 1.47% (mes 7).
- Centinelas Negativos vs. Dominio y Varianza Nula: Las 6 columnas de MISSING_NEGATIVE_COLS codifican ausencias informativas (intended_balcon_amount 74.29%; prev_address_months_count 71.12% con 1.42% de fraude si <0 vs. 0.31% si >=0; bank_months_count 25.66%), justificando SimpleImputer(median, add_indicator=True). En cambio, credit_risk_score < 0 (1.44%, mín. -170) representa puntajes reales válidos (preservados sin imputar) y device_fraud_count vale 0 en el 100% del dataset (var=0), eliminándose in-fold con VarianceThreshold(0.0) (57 atributos de salida). En equidad previa, customer_age >= 50 (18.17%) presenta 2.34% de fraude basal frente a 0.83% en < 50 (2.83x).

2. Arquitectura Anti-Leakage y Efecto Crítico del Umbral Operativo (tau_val vs. 0.50)

- Cero Data Leakage Verificado: Todo ajuste estadístico (NegativeSentinelToNaN, medianas, filtro de varianza nula, StandardScaler y OneHotEncoder) ocurre exclusivamente dentro de X_train en cada fold de sklearn.pipeline.Pipeline, demostrado matemáticamente con 8/8 pruebas unitarias (pytest -v) en tests/test_pipeline_noleakage.py y registrado en MLflow (run 5d187dde64bc4120a6420b5c2335c7cf).
- Hallazgo sobre class_weight='balanced': Reponderar la clase positiva (~89.7x) infla las probabilidades posteriores. Con el umbral ingenuo tau=0.50 en Test, el FPR se dispara a 17.84% (2,646 clientes legítimos bloqueados) y el F1 cae a 0.0851 (Precisión=4.51%). Al calibrar tau_val=0.8173 EXCLUSIVAMENTE en Val sujeto a FPR<=5% (Val FPR=4.95%, Recall=52.41%) y aplicarlo sin fuga a Test, el FPR cae a 4.95% (-72.3% falsos positivos, FP=734) y el F1 sube +96.3% a 0.1672.

3. Tabla Oficial de Resultados Reales de la Línea Base (LogisticRegression balanced)

Evaluación / Subgrupo (Test n=15,000)	AUC-PR (ap)	Recall	FPR	F1-score	ROC-AUC / Detalle Operativo
5-Fold Stratified CV (Train n=70,000)	**0.1494 ± 0.0360**	**--**	**--**	**0.0863 ± 0.0022**	**ROC 0.8857 (var_ap=0.0013)**
Test Global - Umbral ingenuo (tau=0.50)	0.1413	0.7576	0.1784	0.0851	ROC 0.8805 | FP=2,646, TP=125
Test Global - Calibrado Val (tau=0.8173)	**0.1413**	**0.4970**	**0.0495**	**0.1672**	**ROC 0.8805 | FP=734, TP=82, FN=83**
Equidad Edad: <50 (12,211) vs >=50 (2,789)	0.1632 / 0.1552	0.4182 / 0.6545	0.0324 / 0.1251	--	Delta FPR = 0.0927 (> 0.05)
Equidad Empleo (CA-CF) | Ingreso (3 bandas)	0.0056 - 0.5244	CC: 0.7273	CC: 0.1444	--	Gap Emp=0.1444 | Ing=0.0514

4. Diagnóstico de Brechas frente al Hito 1 y Hoja de Ruta hacia el Hito 3

1) Desempeño Primario y Operativo: Aunque ROC-AUC=0.8805 luce elevado, bajo desbalance 1:90 el clasificador lineal solo alcanza AUC-PR CV=0.1494 (Test=0.1413) y Recall@FPR<=5%=0.4970 (a solo 1 verdadero positivo de la meta >=0.50: 82/165). La meta cuantitativa para el Hito 3 queda anclada en AUC-PR CV >= 0.1719 (+15% rel.) o >= 0.1994 (+0.05 abs.).
2) IA Responsable: El umbral global penaliza a mayores de 50 años (FPR 12.51% vs. 3.24%, Delta FPR=0.0927 > 0.05) por mayor prevalencia basal y cupo solicitado en ese estrato.
3) Plan Hito 3 (--mode full): (a) Búsqueda CASH determinista en FLAML con max_iter (sin time_budget) sobre lgbm, xgboost, rf, extra_tree y lrl1 optimizando ap y registrando child runs en MLflow; (b) Comparación controlada class_weight vs. SMOTE estrictamente in-fold en imblearn.pipeline.Pipeline; (c) Calibración de umbrales por subgrupo etario en Val para lograr Delta FPR <= 0.05; y (d) Análisis causal detallado de >= 10 casos reales de error (FP y FN) en Test.

5. Ejecución 100% Reproducible (< 5 Comandos) y Referencias

```
pip install -r requirements.txt  &&  python -m src.data.download
python -m src.models.train --sample-size 100000 --mode baseline  &&  pytest -v
```

Referencias: [1] Russell & Norvig, AIMA 4th ed. (Caps. 19-21), 2020. [2] Studer et al., CRISP-ML(Q), MAKE 3(2), 2021. [3] Jesus et al., Turning the Tables: BAF Dataset Suite, NeurIPS 2022. [4] Saito & Rehmsmeier, PLOS ONE 10(3), 2015. [5] Wang et al., FLAML, MLSys 2021.