Hito 3: Ingenieria de Modelos (CASH + SMOTE In-Fold), Mitigacion de Equidad y Analisis de Errores

Repositorio: fraud-detection-crisp-ml | Ruta C (Russell & Norvig caps. 19-21) | Metodologia: CRISP-ML(Q) | seed=42 | Mejor modelo: FLAML (lgbm)

1. Diseno Experimental Fase 3 CRISP-ML(Q): Manejo de Desbalance In-Fold y Busqueda CASH (FLAML)

Sobre la particion estratificada congelada en Hito 2 (Train n=70.000, Val n=15.000, Test n=15.000; prevalencia 1,103%, SHA-256 7bf10a37...dcf9b809), se contrastaron tres estrategias sin fuga de datos: (i) Ponderacion de costos en Linea Base (LogisticRegression class_weight='balanced'); (ii) Sobremuestreo sintetico SMOTE(sampling_strategy=0.1, seed=42) encapsulado estrictamente en imblearn.pipeline.Pipeline dentro de cada fold de StratifiedKFold(n_splits=5), evaluado tanto con Regresion Logistica como con LightGBM; y (iii) Busqueda CASH en FLAML (max_iter=30 determinista, metric='ap', 5-fold CV) sobre 5 familias (lgbm, xgboost, rf, extra_tree, lrl1), registrando cada familia como child run en MLflow. El estimador ganador fue lgbm, alcanzando AUC-PR CV = 0.1797 (+20.25% relativo y +0.0303 abs. frente al baseline 0.1494, superando ampliamente la meta >= +15%).

2. Resultados Comparativos en 5-Fold CV y Test (n=15.000) y Verificacion de Metas del Hito 1

Modelo / Estrategia	5-Fold CV AUC-PR	Test AUC-PR	Recall@FPR<=5%	Test FPR	Test F1	ROC-AUC / Delta FPR
Baseline LogReg (balanced, tau_val)	0.1494 +/- 0.0360	0.1413	0.4970	0.0495	0.1672	0.8805 | dFPR=0.0927
LogReg + SMOTE in-fold (0.1, tau_val)	0.1575 +/- 0.0346	0.1421	0.5394	0.0502	0.1784	0.8847 | dFPR=0.0811
LGBM + SMOTE in-fold (0.1, tau_val)	0.1562 +/- 0.0315	0.1537	0.5273	0.0457	0.1871	0.8902 | dFPR=0.0718
FLAML lgbm (tau_val unico=0.0355)	0.1743 +/- 0.0517	0.1556	0.5273	0.0496	0.1761	0.8887 | dFPR=0.0786
FLAML lgbm + Equidad Val (tau por edad)	**0.1743 +/- 0.0517**	**0.1556**	**0.5030**	**0.0477**	**0.1738**	**0.8887 | dFPR=0.0070**

3. Auditoria de IA Responsable y Mitigacion Post-Procesamiento de Sesgo Etario (Delta FPR <= 0,05)

Por que ocurre el sesgo con umbral unico: En BAF, el subgrupo age_>=50 tiene una prevalencia basal de fraude 2,83x mayor (2,34% vs. 0,83%), desplazando hacia arriba sus probabilidades predichas. Con un unico umbral global tau_val=0.0355, el modelo ganador presenta FPR(age_<50)=3.51% vs. FPR(age_>=50)=11.38%, generando Delta FPR = 0.0786 (> 0,05). Mitigacion sin leakage: Al calibrar umbrales especificos por grupo exclusivamente en Val sujetos a FPR_g <= 5% (tau_val[age_<50]=0.0273, tau_val[age_>=50]=0.0663) y evaluarlos en Test, el FPR se equilibra en 4.64% (age_<50) y 5.34% (age_>=50), reduciendo la brecha a Delta FPR = 0.0070 (<= 0,05, -91.1%), manteniendo FPR global = 4.77% (<= 5%) y Recall@FPR<=5% = 50.30% (>= 50%, TP=83/165).

4. Analisis Causal de >= 12 Errores Reales en Test (experiments/error_analysis_hito3.json) y Reflexion Critica IA

Variables dominantes (lgbm): current_address_months_count (9.1%), name_email_similarity (8.6%), has_other_cards (6.1%), phone_home_valid (5.6%). Se auditaron 12 casos extremos reales en Test (6 FP + 6 FN) y los 4 cuadrantes de confusion: (a) Falsos Positivos (FP n=707, p_media=0.094): Clientes legitimos que acumulan senales de riesgo (cupo medio 883 vs. 501 en TN; 62.1% en Windows vs. 23.6% en TN; score crediticio 183.9 vs. 128.1). Caso real FP_01_test_idx_7075 (p=0.7846 >= tau=0.0273): cupo solicitado alto (2000), device_os=windows (mayor riesgo basal), keep_alive_session=0 (sesión sin persistencia). (b) Falsos Negativos (FN n=82, p_media=0.017): Fraudes sofisticados de identidad sintetica o robo de sesion que mimetizan clientes de bajo riesgo (cupo medio 593 vs. 1063 en TP; solo 48.8% Windows vs. 78.3% en TP; similitud nombre-correo 0.44 vs. 0.32). Caso real FN_01_test_idx_7589 (p=0.0017 < tau=0.0273): keep_alive_session=1 (emula sesión legítima), device_os=linux (baja tasa basal), cupo solicitado conservador (200). (c) Hallazgo sobre SMOTE y Reflexion IA: Aplicar SMOTE(0.1) in-fold degrada el AUC-PR en modelos lineales (0.1575) y de arboles (0.1562 vs. 0.1797) porque interpolar en un espacio de 57 dimensiones post-OneHot genera puntos sinteticos en regiones solapadas. Asimismo, la auditoria humana detecto y corrigio 3 limitaciones de sugerencias iniciales de IA: threshold snooping en Test, descalibracion de probabilidades bajo class_weight/SMOTE y amplificacion de disparidad etaria con umbral unico.